UTH UNIVERSITY OF TRANSPORT HOCHIMINH CITY

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
THÀNH PHỐ HỒ CHÍ MINH

HP:012012710404

Machine Learning: Regression algorithms

Linear models: Linear Regression, Ridge Regression, Lasso Regression, ElasticNet Regression

Group: 3
Nguyễn Xuân Đông
Mai Hoàng Danh
Võ Khôi Nguyên
Võ Thanh Phú
Trương Thành Công
Nguyễn Minh Nhật
Mai An Thịnh

GVHD: TS. Nguyễn Thị Khánh Tiên

UTH UNIVERSITY OF TRANSPORT HOCHIMINH CITY

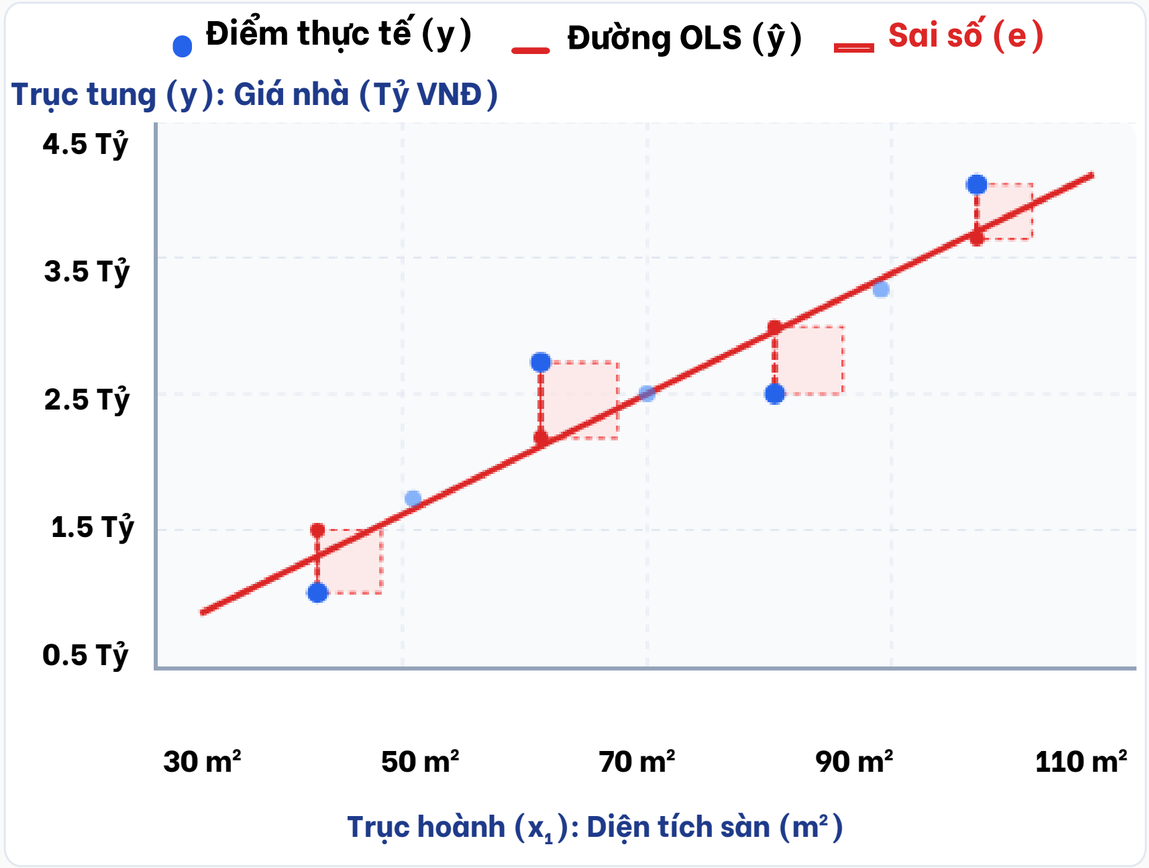
TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI THÀNH PHỐ HỒ CHÍ MINH

Hồi Quy Tuyến Tính (Linear Regression)

Bản Chất Linear Regression

Học có giám sát dự đoán biến mục tiêu liên tục. Đầu ra biến thiên tuyến tính theo các biến đặc trưng đầu vào.

$$\hat{y}(w, x) = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_p x_p$$



1. Phương pháp bình phương tối thiểu (OLS)

$$\mathrm{SSR} = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

2. Giải tích (Normal Equation)

$$\mathbf{w}^* = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

3. Gradient Descent

Khởi tạo w ngẫu nhiên, cập nhật ở từng bước đến khi w tối ưu

UTH UNIVERSITY OF TRANSPORT HOCHIMINH CITY

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI THÀNH PHỐ HỒ CHÍ MINH

Bài toán thực tế & Triển khai

- **Bộ dữ liệu**: housing_market_data.csv (Khảo sát 85 căn nhà, 17 đặc trưng: số phòng, thuế, ô nhiễm, tỷ lệ dân nghèo...).
- **Biến mục tiêu** (y): Giá nhà (house_price - nghìn USD).

Kết quả mô hình

Tiêu chí đánh giá	Linear Regression
R2 Train	0.92 (92%)
R2 Test	**0.59 (59%)**
RMSE	509
Kết luận	Chênh lệch Train-Test 33%

Mô hình bị Overfitting (học vẹt) rất nặng do 17 biến có độ tương quan phức tạp.

```python
import os
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

# Step 1: Đọc dữ liệu thực tế và chuẩn bị X, y
data_path = 'data/housing_market_data.csv'
df = pd.read_csv(data_path)
X = df.drop(columns=['house_price'])
y = df['house_price']

# Step 2: Phân chia tập Train (65%) - Test (35%) & Chuẩn hóa đặc trưng
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.35, random_state=12)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Step 3: Khởi tạo và huấn luyện mô hình Linear Regression (OLS)
model = LinearRegression()
model.fit(X_train_scaled, y_train)

# Step 4: Dự đoán và in kết quả đánh giá mô hình
y_pred = model.predict(X_test_scaled)
print(f"R2 Train : {model.score(X_train_scaled, y_train):.2f}")
print(f"R2 Test  : {r2_score(y_test, y_pred):.2f}")
print(f"RMSE Test: {mean_squared_error(y_test, y_pred)**0.5:.2f}")

```

Ưu Nhược Điểm Của Linear Regression & Trong Thực Tế

Ưu điểm

Đơn giản trực quan: Dễ hiểu và dễ tiếp cận

Dễ giải thích: Nhìn vào trọng số biết ngay biến nào quan trọng.

Tốc độ nhanh: Tính toán, huấn luyện nhanh

Nhược điểm

Đa cộng tuyến: Mô hình bị rối loạn khi các biến có mức độ tương quan cao.

Nguy cơ học vẹt (Overfitting): Dễ học luôn cả nhiễu khi có nhiều biến đặc trưng

Nhạy cảm ngoại lai: Chỉ vài điểm dị biệt là kéo lệch cả đường dự đoán.

Linear Regression: Dùng cho các bài toán cơ bản, quan hệ tuyến tính rõ ràng và ít biến
Ví dụ: dự đoán chiều cao theo tuổi,
dự đoán doanh thu theo chi phí quảng cáo đơn giản,
dự đoán lưu lượng xe dựa trên số lượng xe, thời gian, địa điểm, ...

UTH UNIVERSITY OF TRANSPORT HOCHIMINH CITY

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI THÀNH PHỐ HỒ CHÍ MINH

Ridge Regression

Ridge Regression là một biến thể của hồi quy tuyến tính, sử dụng kỹ thuật L2 Regularization để hạn chế hiện tượng quá khớp (Overfitting) và cải thiện độ ổn định của mô hình, đặc biệt khi dữ liệu có hiện tượng đa cộng tuyến (Multicollinearity) hoặc số lượng biến độc lập lớn hơn số lượng quan sát.

Hàm mục tiêu của Ridge Regression

$$J(w) = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2 + \alpha\sum_{j=1}^{p} w_j^2$$

Mục Tiêu của Ridge Regression

- Cải thiện tính ổn định và khả năng tổng quát hóa (generalization) của mô hình hồi quy tuyến tính.
- Thêm một điều kiện phạt (penalty term) vào hàm mất mát.
- Giảm thiểu độ lớn của các hệ số hồi quy
- Tìm bộ hệ số trọng số w cho các biến độc lập sao cho hàm mục tiêu (dựa trên hàm mất mát bình phương trung bình - MSE) đạt giá trị tối ưu (nhỏ nhất).

UTH UNIVERSITY OF TRANSPORT HOCHIMINH CITY

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI THÀNH PHỐ HỒ CHÍ MINH

Bài toán thực tế & triển khai

Mục tiêu thử nghiệm: Áp dụng Ridge lên cùng tập dữ liệu bất động sản để kiểm chứng khả năng kiểm soát Overfitting.

Kết quả mô hình

Tiêu chí đánh giá	Linear Regression	Ridge Regression	Đánh giá cải tiến
R2 Train	0.92 (92%)	0.81 (81%)	Giảm bớt sự học vẹt
R2 Test	**0.59 (59%)**	**0.72 (72%)**	**Tăng vọt + 13%**
RMSE	509	429	**Sai số giảm**
Kết luận	Lệch Train-Test 33%	Lệch Train-Test 9%	**Kìm hãm Overfitting**

```python
import os
import sys
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import RidgeCV
from sklearn.metrics import mean_squared_error, r2_score

# Tự động cấu hình mã hóa UTF-8 cho Windows Terminal
if hasattr(sys.stdout, "reconfigure"):
    sys.stdout.reconfigure(encoding="utf-8")

# Step 1: Đọc dữ liệu thực tế và chuẩn bị X, y (Tự động nhận diện đường dẫn chuẩn)
base_dir = os.path.dirname(os.path.abspath(__file__))
data_path = os.path.join(base_dir, "data", "housing_market_data.csv")
df = pd.read_csv(data_path)
X = df.drop(columns=["house_price"])
y = df["house_price"]

# Step 2: Phân chia tập Train (65%) - Test (35%) & Chuẩn hóa
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.35, random_state=12
)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Step 3: Tự động tìm alpha tối ưu và huấn luyện bằng RidgeCV (5-Fold Cross-Validation)
model = RidgeCV(cv=5)
model.fit(X_train_scaled, y_train)

# Step 4: Dự đoán và in kết quả đánh giá mô hình
y_pred = model.predict(X_test_scaled)
print(f"Alpha tối ưu (CV): {model.alpha_:.2f}")
print(f"R2 Train : {model.score(X_train_scaled, y_train):.2f}")
print(f"R2 Test  : {r2_score(y_test, y_pred):.2f}")
print(f"RMSE Test: {mean_squared_error(y_test, y_pred) ** 0.5:.2f}")
```

Ưu Nhược Điểm Của Ridge Regression & Trong Thực Tế

Ưu Điểm

- Ngăn chặn quá khớp : Giảm phương sai của các hệ số hồi quy.
- Ổn định số học: Hoạt động ổn định khi các đặc trưng có tương quan cao.
- Giữ lại tất cả đặc trưng: Không đưa hệ số hồi quy về 0.

Nhược Điểm

- Không chọn lọc đặc trưng : Không loại bỏ các đặc trưng không cần thiết, bất lợi với dữ liệu có số chiều cao.
- Độ chệch (Bias): Có thể làm tăng độ chệch, đặc biệt khi mô hình thực sự có nhiều hệ số bằng 0.

Ridge Regression: Chuyên trị các bài toán Đa cộng tuyến cao ngoài đời
Ví dụ: dữ liệu kinh tế vĩ mô có lạm phát - lãi suất - GDP liên quan chặt chẽ với nhau, phân tích tín hiệu từ các cảm biến kỹ thuật, ...

UTH UNIVERSITY OF TRANSPORT HOCHIMINH CITY

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI THÀNH PHỐ HỒ CHÍ MINH

LASSO REGRESSION

LASSO (Least Absolute Shrinkage and Selection Operator) là kỹ thuật điều chỉnh được sử dụng để ngăn ngừa hiện tượng quá khớp (overfitting) trong các mô hình hồi quy tuyến tính

Hàm mục tiêu của Lasso Regression

$$J(\mathbf{w}) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \alpha\sum_{j=1}^{p}|w_j|$$

Mục tiêu của Lasso Regression

- Giảm sai số dự đoán.
- Hạn chế hiện tượng quá khớp (Overfitting).
- Thu nhỏ các hệ số hồi quy.
- Tự động lựa chọn đặc trưng (Feature Selection) bằng cách đưa một số hệ số về đúng 0.

UTH UNIVERSITY OF TRANSPORT HOCHIMINH CITY

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI THÀNH PHỐ HỒ CHÍ MINH

Bài toán thực tế & triển khai

Mục tiêu thử nghiệm: Áp dụng Lasso nhằm thực hiện chọn lọc đặc trưng— tự động triệt tiêu các biến dư thừa để tinh gọn mô hình mà vẫn duy trì độ chính xác cao.

Kết quả mô hình

Tiêu chí đánh giá	Linear (OLS)	Ridge Regression	Lasso Regression
R2 Train	0.92 (92%)	0.81 (81%)	**0.74 (74%)**
R2 Test	0.59 (59%)	0.72 (72%)	**0.67 (67%)**
RMSE	509	422	**458**
Số biến bị loại	0 / 17 biến	0 / 17 biến	**11 / 17 biến**

```python
import os
import sys
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LassoCV
from sklearn.metrics import mean_squared_error, r2_score

# Tự động cấu hình mã hóa UTF-8 cho Windows Terminal
if hasattr(sys.stdout, "reconfigure"):
    sys.stdout.reconfigure(encoding="utf-8")

# Step 1: Đọc dữ liệu thực tế và chuẩn bị X, y (Tự động nhận diện đường dẫn chuẩn)
base_dir = os.path.dirname(os.path.abspath(__file__))
data_path = os.path.join(base_dir, "data", "housing_market_data.csv")
df = pd.read_csv(data_path)
X = df.drop(columns=["house_price"])
y = df["house_price"]

# Step 2: Phân chia tập Train (65%) - Test (35%) & Chuẩn hóa
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.35, random_state=12
)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Step 3: Tự động tìm alpha tối ưu và huấn luyện bằng LassoCV (5-Fold Cross-Validation)
model = LassoCV(cv=5, random_state=12)
model.fit(X_train_scaled, y_train)

# Step 4: Dự đoán và in kết quả đánh giá mô hình
y_pred = model.predict(X_test_scaled)
num_zeros = sum(model.coef_ == 0)

print(f"Alpha tối ưu (CV): {model.alpha_:.2f}")
print(f"R2 Train : {model.score(X_train_scaled, y_train):.2f}")
print(f"R2 Test  : {r2_score(y_test, y_pred):.2f}")
print(f"RMSE Test: {mean_squared_error(y_test, y_pred) ** 0.5:.2f}")
print(f"Biến bị loại bỏ (=0): {num_zeros} / {len(model.coef_)}")
```

Ưu Nhược Điểm Của Lasso Regression & Trong Thực Tế

Ưu điểm

- Tự chọn biến, mô hình thưa, dễ diễn giải.
- Giảm overfitting, tính toán nhanh, bài toán lồi.

Nhược điểm

- Với nhóm biến tương quan cao, chỉ chọn một biến và lựa chọn thiếu ổn định.
- Hệ số bị thiên lệch (bias) do bị co.
- Khó suy luận thống kê (p-value, khoảng tin cậy).

Lasso Regression: Chuyên trị các bài toán Dữ liệu lớn có số chiều khổng lồ
Ví dụ: Trong Y sinh học - từ 20,000 gen di truyền lọc ra đúng 5 gen gây bệnh ung thư;
Trong Thương mại điện tử - từ hàng trăm hành vi của khách hàng lọc ra vài yếu tố quyết định để chốt đơn.

UTH UNIVERSITY OF TRANSPORT HOCHIMINH CITY

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI THÀNH PHỐ HỒ CHÍ MINH

ElasticNet Regression

Vì sao cần ElasticNet thay vì Lasso?

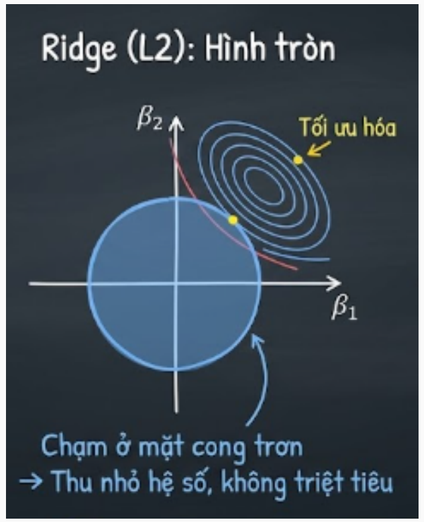
- Khái niệm: Là mô hình kết hợp đồng thời chuẩn phạt L1 (Lasso) và L2 (Ridge).
- Giải quyết điểm yếu của Lasso: Khi các biến có tính đa cộng tuyến nhóm, Lasso thường chọn bừa 1 biến và vứt bỏ các biến còn lại. ElasticNet kích hoạt Hiệu ứng gom nhóm của Ridge để cùng giữ lại các biến quan trọng.

Hàm mục tiêu của Lasso Regression

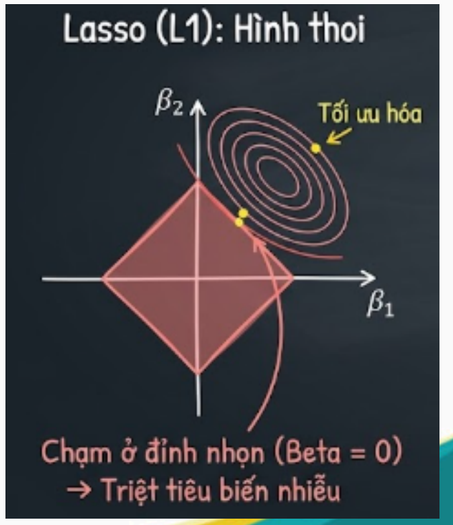
$$J(\mathbf{w}) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \alpha\left[\rho\sum_{j=1}^{p}|w_j| + \frac{1-\rho}{2}\sum_{j=1}^{p}w_j^2\right]$$

Bản chất hình học của vùng ràng buộc ElasticNet

- Lasso: Hình thoi (có đỉnh nhọn → lọc biến về 0).
- Ridge: Hình tròn (cạnh cong → co nhỏ trọng số, không triệt tiêu).
- ElasticNet: Hình thoi bo góc (vừa có đỉnh nhọn để lọc biến, vừa có cạnh cong để gom nhóm biến tương quan).







UTH UNIVERSITY OF TRANSPORT HOCHIMINH CITY

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI THÀNH PHỐ HỒ CHÍ MINH

Bài toán thực tế & triển khai

- **Mục tiêu thử nghiệm**: Kết hợp chọn lọc biến của L1 và gom nhóm biến tương quan của L2. Đánh giá ElasticNet so với cả 3 mô hình Linear, Ridge và Lasso trước đó.

Kết quả mô hình

Tiêu chí đánh giá	1. Linear (OLS)	2. Ridge Regression	3. Lasso Regression	4. ElasticNet
R2 Train	**0.92 (92%)**	0.81 (81%)	0.74 (74%)	0.77 (77%)
R2 Test	0.59 (59%)	**0.72 (72%)**	**0.67 (67%)**	**0.70 (70%)**
RMSE	509	422	458	**438**
Số biến bị loại bỏ về 0	0 / 17	0 / 17	**11 / 17 biến**	**4 / 17 biến**
Kết luận thực tế	**Overfitting nặng** (Lệch Train-Test 33%)	**Kìm hãm Overfitting đỉnh nhất** (Lệch chỉ 9%)	**Lọc biến rác mạnh nhất**, tiết kiệm chi phí	**Cân bằng tối ưu toàn diện** giữa độ chính xác & độ gọn

```python
import os
import sys
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import ElasticNetCV
from sklearn.metrics import mean_squared_error, r2_score

# Step 1: Đọc dữ liệu thực tế chung của nhóm
base_dir = os.path.dirname(os.path.abspath(__file__))
data_path = os.path.join(base_dir, "data", "housing_market_data.csv")
df = pd.read_csv(data_path)
X = df.drop(columns=["house_price"])
y = df["house_price"]

# Step 2: Phân chia tập Train (65%) - Test (35%) & Chuẩn hóa
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.35, random_state=12
)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Step 3: Tự động tìm alpha và l1_ratio tối ưu bằng ElasticNetCV (5-Fold CV)
model = ElasticNetCV(l1_ratio=[0.1, 0.3, 0.5, 0.7, 0.9], cv=5, random_state=12)
model.fit(X_train_scaled, y_train)

# Step 4: Dự đoán và in kết quả đánh giá mô hình
y_pred = model.predict(X_test_scaled)
num_zeros = sum(model.coef_ == 0)

print(f"Alpha tối ưu (CV)   : {model.alpha_:.2f}")
print(f"L1 Ratio tối ưu (CV): {model.l1_ratio_:.2f}")
print(f"R2 Train : {model.score(X_train_scaled, y_train):.2f}")
print(f"R2 Test  : {r2_score(y_test, y_pred):.2f}")
print(f"RMSE Test: {mean_squared_error(y_test, y_pred) ** 0.5:.2f}")
print(f"Biến bị loại bỏ (=0): {num_zeros} / {len(model.coef_)}")
```

Ưu Nhược Điểm Của ElasticNet Regression & Trong Thực Tế

Ưu điểm

- Dung hòa Ridge & Lasso: Vừa kìm hãm Overfitting (L2), vừa tự động lọc biến rác (L1).
- Gom nhóm biến tương quan: Giữ lại cả nhóm biến quan trọng thay vì chọn bừa 1 biến như Lasso.
- Xử lý tốt khi p>n: Hoạt động mạnh mẽ khi số lượng đặc trưng lớn hơn số lượng mẫu.
- Linh hoạt cao: Dễ dàng tùy biến tỷ lệ phối hợp qua tham số l1_ratio.

Nhược điểm

- Tốn chi phí tính toán: Phải tối ưu đồng thời cả 2 siêu tham số (αvà l1_ratio).
- Hiện tượng co kép : Cả 2 chuẩn phạt cùng ép có thể làm tăng nhẹ độ chệch (Bias).
- Khó cấu hình hơn: Đòi hỏi quét tìm tham số (GridSearchCV) phức tạp hơn Ridge và Lasso.

ElasticNet Regression: Chuyên trị các bài toán phức tạp vừa có nhiều biến nhiễu, vừa có các nhóm đặc trưng tương quan mạnh

Ví dụ: Trong Tài chính - Chứng khoán: Lọc bỏ hàng trăm chỉ số thị trường rác, đồng thời giữ lại trọn vẹn cả nhóm cổ phiếu cùng ngành biến động song song;

Trong Y sinh học: Vừa loại bỏ hàng ngàn gen vô hại, vừa bắt trọn cả cụm gen chuỗi sinh học cùng tương tác gây bệnh ung thư.


Thank
you